

Construí um agente de IA para auditar um catálogo do Databricks.

34 → 89

Esse é o índice de saúde do catálogo, antes e depois de uma execução. Tudo nos próximos nove slides é o que realmente aconteceu até chegar lá — incluindo as partes que eu errei.

Uma coluna guarda o valor

47382

Isso é **47 segundos** ou **47 minutos**? Os dois são plausíveis. Um deles está errado por um fator de mil.

Dá pra perfilar essa coluna o dia inteiro — nulos, cardinalidade, amostras. Nada disso responde a pergunta, porque a resposta não está no dado. Está na documentação do fornecedor. É a única coisa que um recurso que só lê seu dado estruturalmente não consegue fazer.

Cada descrição é gerada e ancorada na documentação do próprio sistema de origem.

79/79

colunas documentadas

\$0,0048

custo modelado, preço de
tabela

118s

pro catálogo inteiro

O plano gratuito não cobra nada, então esse número é modelado, não faturado — e o repositório deixa isso explícito em vez de citar um valor que não pagou.

Meu primeiro teste **estava viciado**, e levei um dia pra perceber.

Eu escrevi a documentação.
Eu gerei o dado.
Eu declarei o resultado.

Esse teste não podia falhar. Um teste que não pode falhar não prova nada — só prova que o texto que eu botei no prompt voltou do prompt.

Então refiz contra material que nenhum dos dois lados escreveu.

A especificação oficial `TPC-H v3.0.1`, do tpc.org, contra as tabelas de amostra que vêm no Databricks. 61 colunas.

varredura limpa → 6 acertos reais

"56 de 61 mudaram" soa melhor e não significa quase nada — isso é só reescrita. Cerca de 6 mudaram de um jeito que importava de verdade. Seis em 61, num dado que eu não toquei, é um resultado real. A varredura limpa era um espelho.

A resposta certa já estava **no prompt dele**. Ele ignorou.

Três colunas do TPC-H guardam só uma letra — a regra exata de derivação tinha sido recuperada e estava no contexto.

O modelo respondeu: "O for open, F for final"

Um chute confiante e familiar sobre um benchmark famoso — vencendo o texto que ele realmente recebeu. O ajuste não foi melhorar retrieval. Foi um parágrafo dizendo pra usar a regra em vez do instinto próprio.

Pra achar tabela órfã, a ferramenta precisa ler a tabela.

Ler é exatamente o que "órfã" significa a ausência de. Três tentativas antes do ajuste se firmar:

01 - **falhou**

Subtrair a janela de tempo do scan

O Unity Catalog registra evento de forma assíncrona — as próprias leituras da ferramenta caiam fora da própria janela.

02 - **falhou**

Dar folga de 20 minutos na janela

Resolveu isso, e engoliu uma sessão real de analista que aconteceu 4 minutos depois de um scan.

03 - **funcionou**

Marcar cada instrução, comparar por identidade

Não por horário. O agente ficou invisível pra si mesmo — verificado na mesma execução que perfilou todas as tabelas.

Cada descrição, em inglês e português — numa única chamada ao modelo.

\$0,0048 → \$0,0062

+29% pelo dobro da cobertura, porque a parte cara do prompt é idêntica pros dois idiomas.

`wrapUpCode continua wrapUpCode`

`"F" nunca vira "final"`

Não é uma sequência de slides. É um portal que dá pra abrir de verdade.

governance_lab

ENPT

scan 4900c46f · 2026-09-10
15:31 UTC

Search tables and columns

Ask

Overview

GOLD

sinistralidade_mensal

RAW

apolices

clientes

legado_apolices_2017

sinistros

RAW_GENESYS

conversation_details

queue_daily_metrics

SILVER

apolices_curated

STAGING

cad_gen_2021

import_backup_2024

SOURCE DOCUMENTATION

\$ genesys_cloud

\$ legacy_crm

\$ seguracore

\$ tpch_spec

Generated by lakehouse-governance-agent

GOVERNANCE_LAB

Catalog documentation

Every description here was generated from the data *and* from the documentation of the system each table came from. Open a table to see which passages produced its descriptions.

34 — 89

catalog health score, before and after one run

89 comments written to Unity Catalog across 10 tables in 119s, using 18.877 tokens — \$0.0048 at list price. Modelled, not billed: the run was made on a free tier that charges nothing.

Descriptions are generated in English and Portuguese in the same model call: \$0.0062 for both, against \$0.0048 for English alone.

COVERAGE BY SCHEMA

raw	100% · 32 cols
raw_genesys	100% · 24 cols
staging	100% · 12 cols
silver	100% · 8 cols
gold	100% · 3 cols

FINDINGS 17 open, ranked by what they oblige someone to do

HIGH	raw.clientes	5 personal-data columns	needs a masking policy and a retention decision
HIGH	raw_genesys.conversation_details	3 personal-data columns	needs a masking policy and a retention decision
HIGH	staging.cad_gen_2021	6 personal-data columns	needs a masking policy and a retention decision
HIGH	staging.import_backup_2024	2 personal-data columns	needs a masking policy and a retention decision
MEDIUM	raw.legado_apolices_2017	never read	2.6 KB nobody has queried
MEDIUM	staging.import_backup_2024	never read	2.2 KB nobody has queried
LOW	raw.apolices	1 dead column	always null or a single repeated value
LOW	raw.apolices	fragmented	6 files for 35.4 KB

Clique em qualquer tabela. Cada descrição linka pro trecho exato da documentação que a gerou.

**No que eu ainda apostaria
contra — e o que já está
funcionando.**

16

colunas com dado
pessoal encontradas

2

tabelas realmente nunca
lidas

70

testes, sem precisar de
nenhum segredo

Texto completo, cada commit, as tentativas que falharam
incluídas — link no primeiro comentário.